




รายงาน

เรื่อง Shared Memory

จัดทำโดย



เสนอ

อาจารย์ศักดิ์ระพี ไพศาลนันท์

รายงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตร์และเทคโนโลยีอุตสาหกรรม

คณะวิศวกรรมศาสตร์และเทคโนโลยีอุตสาหกรรม สาขาวิชาอิเล็กทรอนิกส์และระบบคอมพิวเตอร์

รายวิชาวิศวกรรมระบบปฏิบัติการเบื้องต้น 618344 ภาคเรียนที่ 1 ปีการศึกษา 2566

มหาวิทยาลัยศิลปากร วิทยาเขตพระราชวังสนามจันทร์

Shared Memory คืออะไร

การแสดงผลทางจอภาพของคอมพิวเตอร์ จำเป็นต้องมีการประมวลผลและใช้พื้นที่หน่วยความจำสำหรับการแสดงผลกราฟิก โดยเฉพาะงานด้านมัลติมีเดียที่จำเป็นต้องใช้การ์ดจอที่มีประสิทธิภาพสูงมาช่วยเพิ่มประสิทธิภาพในการทำงาน แต่สำหรับเครื่องที่ใช้งานทั่วไปแล้วนิยมใช้วิธี Shared Memory แทนการใช้การ์ดจอ


Shared Memory คือวิธีการแบ่งพื้นที่หน่วยความจำจากแรม เพื่อใช้สำหรับการแสดงผลด้านกราฟิก โดยทำงานร่วมกับชิปเซตการ์ดจอแบบที่ติดตั้งบนเมนบอร์ด การ Shared Memory สามารถทำได้สูงสุดที่ 512 MB วิธีนี้มีประโยชน์คือช่วยให้เครื่องคอมพิวเตอร์ที่ใช้งานทั่ว ๆ ไปตามสำนักงาน สามารถแสดงผลด้านกราฟิกดีขึ้นระดับหนึ่ง หรือสามารถใช้งานโปรแกรมตกแต่งรูปภาพบางโปรแกรมได้

แต่ก็มีข้อเสียคือ การ Shared Memory จะทำให้พื้นที่หน่วยความจำจากแรมลดน้อยลง ทำให้ประสิทธิภาพการทำงานโดยรวมของระบบลดลงด้วย อาการที่มักจะพบบ่อยก็คือ เมื่อมีการใช้งานโปรแกรมที่ต้องใช้พื้นที่แรมมาก ๆ จะทำให้เครื่องทำงานช้าลง และเกิดอาการค้างหรือดับไปในที่สุด ซึ่งจะต้องแก้ไขปัญหานี้โดยการติดตั้งการ์ดจอเพื่อใช้งานเฉพาะด้านแทน

หลักการทำงานของ Shared Memory

หน่วยความจำที่ใช้ร่วมกันเป็นหน่วยความจำที่ใช้ร่วมกันเป็นหน่วยความจำที่อาจเข้าถึงได้พร้อมกัน โดยโปรแกรมหลายโปรแกรมที่มีความตั้งใจที่จะให้การสื่อสารในหมู่พวกเขาหรือหลีกเลี่ยงการสำเนาซ้ำซ้อน หน่วยความจำที่ใช้ร่วมกันเป็นวิธีการส่งผ่านข้อมูลระหว่างโปรแกรมอย่างมีประสิทธิภาพ ขึ้นอยู่กับบริบท โปรแกรมอาจทำงานบนโปรเซสเซอร์ตัวเดียวหรือบนโปรเซสเซอร์แยกกันหลายตัว

การใช้หน่วยความจำสำหรับการสื่อสารภายในโปรแกรมเดียวเช่นในหลายเธรดเรียกอีกอย่างว่า หน่วยความจำแบบแบ่งใช้ที่อาจเข้าถึงได้พร้อมกันโดยโปรแกรมหลายโปรแกรมที่มีความตั้งใจที่จะให้การสื่อสารในหมู่พวกเขาหรือหลีกเลี่ยงการสำเนาซ้ำซ้อน หน่วยความจำที่ใช้ร่วมกันเป็นวิธีการส่งผ่านข้อมูลระหว่างโปรแกรมอย่างมีประสิทธิภาพ ขึ้นอยู่กับบริบทโปรแกรมอาจทำงานบนโปรเซสเซอร์ตัวเดียวหรือบนโปรเซสเซอร์แยกกันหลายตัว



ภาพประกอบของระบบหน่วยความจำแบบแบ่งใช้ของโปรเซสเซอร์สามตัว

Shared Memory ในระบบต่างๆ

ในฮาร์ดแวร์

ในฮาร์ดแวร์คอมพิวเตอร์หน่วยความจำที่ใช้ร่วมกันหมายถึง (ขนาดใหญ่โดยทั่วไป) บล็อกของหน่วยความจำเข้าถึงโดยสุ่ม (RAM) ที่สามารถเข้าถึงได้โดยแตกต่างกันหลายหน่วยประมวลผลกลาง (ซีพียู) ในระบบคอมพิวเตอร์แบบมัลติโพรเซสเซอร์

ระบบหน่วยความจำที่ใช้ร่วมกันอาจใช้

- การเข้าถึงหน่วยความจำแบบสม่ำเสมอ (UMA): โพรเซสเซอร์ทั้งหมดแชร์หน่วยความจำกายภาพอย่างสม่ำเสมอ
- การเข้าถึงหน่วยความจำแบบไม่สม่ำเสมอ (NUMA): เวลาในการเข้าถึงหน่วยความจำขึ้นอยู่กับตำแหน่งหน่วยความจำที่สัมพันธ์กับโพรเซสเซอร์
- สถาปัตยกรรมหน่วยความจำแคชเท่านั้น (COMA): หน่วยความจำโลคัลสำหรับโพรเซสเซอร์ที่แต่ละโหนดถูกใช้เป็นแคชแทนหน่วยความจำหลักจริง

ระบบหน่วยความจำแบบแบ่งใช้นั้นค่อนข้างง่ายในการตั้งโปรแกรมเนื่องจากโพรเซสเซอร์ทั้งหมดแชร์ข้อมูลมุมมองเดียวและการสื่อสารระหว่างโพรเซสเซอร์อาจรวดเร็วพอ ๆ กับการเข้าถึงหน่วยความจำไปยังตำแหน่งเดียวกัน ปัญหาเกี่ยวกับระบบหน่วยความจำที่ใช้ร่วมกันคือซีพียูจำนวนมากต้องการการเข้าถึงหน่วยความจำอย่างรวดเร็วและมีแนวโน้มที่จะเป็นหน่วยความจำแคชซึ่งมีสองภาวะแทรกซ้อน:

- การลดระดับเวลาในการเข้าถึง: เมื่อโพรเซสเซอร์หลายตัวพยายามเข้าถึงตำแหน่งหน่วยความจำเดียวกันจะทำให้เกิดข้อขัดแย้ง พยายามที่จะเข้าถึงหน่วยความจำอยู่บริเวณใกล้เคียงสถานที่อาจก่อให้เกิดการแบ่งปันเท็จ คอมพิวเตอร์หน่วยความจำที่ใช้ร่วมกันไม่สามารถปรับขนาดได้นักส่วนใหญ่มีโพรเซสเซอร์ 10 ตัวหรือน้อยกว่านั้น
- ขาดการเชื่อมโยงกันของข้อมูล: เมื่อใดก็ตามที่แคชหนึ่งได้รับการอัปเดตด้วยข้อมูลที่อาจใช้โดยโพรเซสเซอร์อื่นการเปลี่ยนแปลงจะต้องสะท้อนให้เห็นถึงโพรเซสเซอร์อื่นมิฉะนั้นโพรเซสเซอร์ที่แตกต่างกันจะทำงานกับข้อมูลที่ไม่ต่อเนื่องกัน โปรโตคอลการเชื่อมโยงแคชดังกล่าวสามารถทำงานได้ดีเมื่อมีการเข้าถึงข้อมูลที่ใช้ร่วมกันระหว่างโพรเซสเซอร์หลายตัวที่มีประสิทธิภาพสูงมากในทางกลับกันบางครั้งอาจมีงานหนักเกินไปและกลายเป็นคอขวดของประสิทธิภาพ

เทคโนโลยีเช่นสวิตช์คาน , HyperTransportหรือfront-side busสามารถนำมาใช้เพื่อรองรับคอขวดผล

ในกรณีของสถาปัตยกรรมระบบที่แตกต่างกัน (สถาปัตยกรรมตัวประมวลผลที่รวมตัวประมวลผลประเภทต่างๆเช่นซีพียูและGPUกับหน่วยความจำที่ใช้ร่วมกัน) หน่วยจัดการหน่วยความจำ (MMU) ของซีพียูและหน่วยจัดการหน่วยความจำอินพุต - เอาท์พุต (IOMMU) ของ GPU ต้องแชร์ลักษณะบางอย่างเช่นพื้นที่ที่อยู่ทั่วไป

ทางเลือกอื่นสำหรับหน่วยความจำแบบแบ่งใช้คือหน่วยความจำแบบกระจายและหน่วยความจำแบบแบ่งใช้แบบกระจายซึ่งแต่ละชุดมีปัญหาที่คล้ายกัน

ในซอฟต์แวร์

ในซอฟต์แวร์คอมพิวเตอร์หน่วยความจำที่ใช้ร่วมกันเป็นอย่างไรอย่างหนึ่ง

- วิธีการสื่อสารระหว่างกระบวนการ (IPC) คือวิธีการแลกเปลี่ยนข้อมูลระหว่างโปรแกรมที่ทำงานในเวลาเดียวกัน กระบวนการหนึ่งจะสร้างพื้นที่ในRAMซึ่งกระบวนการอื่น ๆ สามารถเข้าถึงได้
- วิธีการประหยัดพื้นที่หน่วยความจำโดยกำหนดทิศทางการเข้าถึงสิ่งที่ปกติจะเป็นสำเนาของข้อมูลไปยังอินสแตนซ์เดียวแทนโดยใช้การแมปหน่วยความจำเสมือนหรือด้วยการสนับสนุนอย่างชัดเจนของโปรแกรมที่เป็นปัญหา ส่วนใหญ่มักใช้สำหรับไลบรารีที่ใช้ร่วมกันและสำหรับExecute in place (XIP)

ตั้งแต่กระบวนการทั้งสองสามารถเข้าถึงพื้นที่หน่วยความจำที่ใช้ร่วมกันเช่นหน่วยความจำทำงานปกตินี้เป็นวิธีที่รวดเร็วมากในการติดต่อสื่อสาร (เมื่อเทียบกับกลไกอื่น ๆ ของ IPC เช่นชื่อ pipes , ช็อกเก็ตโดเมนยูนิคซ์หรือCORBA) ในทางกลับกันมันสามารถปรับขนาดได้น้อยกว่าตัวอย่างเช่นกระบวนการสื่อสารต้องทำงานบนเครื่องเดียวกัน (ของวิธี IPC อื่น ๆ เฉพาะช็อกเก็ตโดเมนอินเทอร์เน็ตเท่านั้นไม่ใช่ช็อกเก็ตโดเมน Unix - สามารถใช้เครือข่ายคอมพิวเตอร์ได้) และต้องดูแล นำไปสู่ปัญหาควรหลีกเลี่ยงหากกระบวนการร่วมกันหน่วยความจำที่กำลังทำงานอยู่บนซีพียูแยกต่างหากและสถาปัตยกรรมพื้นฐานไม่แคชเชื่อมโยงกัน

IPC โดยหน่วยความจำที่ใช้ร่วมกันถูกนำมาใช้เช่นการโอนภาพระหว่างโปรแกรมประยุกต์และเซิร์ฟเวอร์ Xบนระบบยูนิคซ์หรือภายในวัตถุ IStream กลับโดย CoMarshalInterThreadInterfaceInStream ในห้องสมุด COM ภายใต้ของ Windows

โดยทั่วไปแล้วไลบรารีแบบไดนามิกจะถูกเก็บไว้ในหน่วยความจำเพียงครั้งเดียวและแมปกับหลายกระบวนการและเฉพาะเพจที่ต้องปรับแต่งสำหรับแต่ละกระบวนการ (เนื่องจากสัญลักษณ์ที่แก้ไขต่างที่นั่น) จะซ้ำกันโดยปกติจะมีกลไกที่เรียกว่าcopy-on-writeที่โปร่งใส คัดลอกหน้าเมื่อพยายามเขียนจากนั้นให้เขียนบนสำเนาส่วนตัวได้สำเร็จ

บทสรุป

การแสดงผลทางจอภาพของคอมพิวเตอร์ จำเป็นต้องมีการประมวลผลและใช้พื้นที่หน่วยความจำสำหรับการแสดงภาพกราฟิก โดยเฉพาะงานด้านมัลติมีเดียที่จำเป็นต้องใช้การ์ดจอที่มีประสิทธิภาพสูงมาช่วยเพิ่มประสิทธิภาพในการทำงาน แต่สำหรับเครื่องที่ใช้งานทั่วไปแล้วนิยมใช้วิธี Shared Memory แทนการใช้การ์ดจอ

เป็นหน่วยความจำที่ไม่มีการจำกัดขนาดของพื้นที่ตายตัวสำหรับข้อมูลแต่ละประเภทว่าต้องเป็นพื้นที่เท่าไรหรือข้อมูลทุกประเภทต่างก็แชร์พื้นที่เก็บข้อมูลอยู่ภายในหน่วยความจำก้อนใหญ่ก้อนเดียวอยากจะเก็บข้อมูลประเภทไหนก็ทำได้ไม่จำกัดจนกว่าหน่วยความจำภายในเครื่องทั้งหมดจะเต็ม ซึ่งทำให้มีความยืดหยุ่นและเป็นอิสระต่อการใช้งานมากกว่าและยังสามารถใช้ได้ทั้งในระบบปฏิบัติการฮาร์ดแวร์และซอฟต์แวร์อีกด้วย

บรรณานุกรม

<https://www.comgeeks.net/shared-memory/index.htm> (ความหมาย)

https://hmong.in.th/wiki/Shared_memory (ระบบการทำงาน)

<https://medium.com/iamgoangle/share-memory-by-communicating-> (วิธีการทำงาน)